

ST-WAM 三任务 LIBERO-Plus 消融实验报告

报告日期：2026-09-07 实验状态：训练与评测全部完成 目标论文：arXiv:2607.28993 实验范围：LIBERO-Object 三任务低成本趋势验证

1. 摘要

本实验比较三种 future prediction 表征：DINO、VAE，以及不使用 CAIR 的 VAE+DINO Dual-Space。三个模型采用相同训练数据、随机种子、优化步数和全局 batch size，并在完全相同的 745 个 LIBERO-Plus case 上进行配对评测。

主要结果如下：

- DINO : LIBERO-Plus 成功率 60.13% ；
- VAE : LIBERO-Plus 成功率 82.15% ；
- VAE+DINO : LIBERO-Plus 成功率 87.79% ；
- Dual 相对 VAE 提升 5.64 个百分点，case-level 配对 bootstrap 95% CI 为 [2.95, 8.46]pp，McNemar 精确检验 $p=8.98\times10^{-5}$ ；
- Dual 的主要优势集中于 Camera Viewpoints、Background Textures 和 Sensor Noise ；在 Robot Initial States 与 Objects Layout 上未优于 VAE。

因此，当前实验支持“VAE+DINO 比单独使用一种 future representation 更稳健”的趋势结论。由于只覆盖三个基础任务、一个训练 seed，且每个 Plus case 只运行一次，本结果不能替代论文全量复现。

2. 实验目的

论文报告的 LIBERO-Plus 消融结果为：

Variant	Future prediction	Intent conditioning	LIBERO	LIBERO-Plus
Fast-WAM	VAE	None	97.6	51.5
DINO Future Only	DINO	None	96.3	39.7
Dual-Space w/o CAIR	VAE+DINO	None	97.8	66.4

本实验不追求完整复现上述绝对数值，而是在可控计算预算下回答以下问题：

1. VAE+DINO 是否比 VAE-only 和 DINO-only 获得更高的 LIBERO-Plus 成功率；
2. 提升主要来自哪类分布变化；
3. 单任务实验中 Dual 与 VAE 差异不明显，是否与数据多样性不足或任务专门化有关。

3. 实验设置

3.1 数据与任务

训练数据来自 LeRobot v3：

```
/mnt/data/embodied_datasets/public_datasets_staging/lerobot_v3_0/libero/libero_object
```

固定使用以下三个 LIBERO-Object 任务，任务在评测之前确定：

LeRobot task index	Clean LIBERO task id	任务	Episodes	Plus cases
1	3	pick up the bbq sauce and place it in the basket	50	292
4	1	pick up the cream cheese and place it in the basket	50	173
7	9	pick up the orange juice and place it in the basket	50	280
合计	—	—	150	745

每个任务按 episode 进行确定性 80/20 划分，共约 120 个训练 episodes 和 30 个验证 episodes。三个模型复用 DINO 训练生成的同一份 `dataset_stats.json`，避免归一化统计差异。

3.2 训练配置

配置	DINO	VAE	VAE+DINO
Optimizer steps	1,500	1,500	1,500
GPUs	4×A800 80GB	4×A800 80GB	4×A800 80GB
Per-GPU batch	4	8	2
Gradient accumulation	8	4	16
Global batch	128	128	128
Learning rate	1e-4	1e-4	1e-4
Seed	42	42	42
Loss weights	DINO:Action = 1:1	VAE:Action = 1:1	VAE:DINO:Action = 1:0.02:1
Intent conditioning / CAIR	None	None	None

三种模型串行训练，checkpoint 位于：

```
/mnt/data/emodied_datasets/ST-WAM/checkpoints/three_task/
```

3.3 评测协议

- Clean：每个基础任务运行 50 次 rollout，每个模型共 150 次；
- LIBERO-Plus：三个任务的全部 745 个 case，每个 case 运行一次；
- 三个模型使用相同 case、任务定义、归一化统计和 seed；
- Plus case 按四张 GPU 分片并行执行；
- 使用 LeRobot v3 图像及夹爪动作约定：图像不旋转，夹爪为 LIBERO 原生 `-1=open`, `+1=close`；
- Plus 分类数量为 Camera 93、Robot 124、Language 103、Light 87、Background 92、Noise 126、Layout 120。

4. 完整性检查

评测状态为 **COMPLETE**。每个模型均生成：

- 3/3 个 Clean 任务结果；
- 745/745 个 LIBERO-Plus case 结果；
- Clean、Plus 和七类扰动汇总文件。

结果目录中 DINO Clean 的 `worker_gpu0_failed_tasks.jsonl` 是首次运行时 EGL vendor 未注册留下的历史记录。修复 EGL 后该任务及全部 case 已成功重跑，最终结果文件完整，因此该历史记录不影响统计。

5. 总体结果

Variant	Clean	Plus successes	LIBERO-Plus	Plus Wilson 95% CI	Robustness drop
DINO	138/150 = 92.00%	448/745	60.13%	[56.58%, 63.59%]	31.87pp
VAE	150/150 = 100.00%	612/745	82.15%	[79.23%, 84.73%]	17.85pp
VAE+DINO	149/150 = 99.33%	654/745	87.79%	[85.24%, 89.94%]	11.54pp

Dual 在 Clean 上与 VAE 基本持平，但在 Plus 上多成功 42 个 case，并将相对 Clean 的鲁棒性下降从 VAE 的 17.85pp 降低到 11.54pp。

6. 配对统计检验

由于三个模型评测的是同一组 745 个 case，可直接比较每个 case 的成败。下表的置信区间来自 50,000 次 case-level paired bootstrap；p 值来自双侧 McNemar 精确检验。

对比	成功率差	95% bootstrap CI	前者独占成功	后者独占成功	McNemar p
Dual – VAE	+5.64pp	[+2.95, +8.46]pp	77	35	8.98×10^{-5}
Dual – DINO	+27.65pp	[+24.16, +31.14]pp	220	14	8.80×10^{-49}
VAE – DINO	+22.01pp	[+17.99, +26.17]pp	221	57	5.80×10^{-24}

在当前 case 集合上，Dual 相对 VAE 的总体提升有明确统计证据。但 745 个 case 聚类于三个基础任务，不能等同于 745 个完全独立任务；case-level p 值会高估结论向新任务推广时的确定性。

7. 分任务结果

7.1 Clean

任务	DINO	VAE	VAE+DINO
BBQ sauce	38/50 = 76.00%	50/50 = 100.00%	50/50 = 100.00%
Cream cheese	50/50 = 100.00%	50/50 = 100.00%	50/50 = 100.00%
Orange juice	50/50 = 100.00%	50/50 = 100.00%	49/50 = 98.00%

DINO 在 BBQ sauce 的 Clean 成功率只有 76%，说明该模型在此任务上首先存在基础策略拟合不足；其较低的 Plus 成功率不能全部解释为分布外泛化失败。

7.2 LIBERO-Plus

任务	Cases	DINO	VAE	VAE+DINO	Dual–VAE
BBQ sauce	292	28.42%	86.30%	89.38%	+3.08pp
Cream cheese	173	75.14%	76.88%	87.86%	+10.98pp
Orange juice	280	83.93%	81.07%	86.07%	+5.00pp

Dual 的三个任务成功率集中于 86.07%–89.38%，任务间波动明显小于 DINO 和 VAE。逐任务的 Dual–VAE 配对结果为：

任务	差值	95% bootstrap CI	McNemar p	判断
BBQ sauce	+3.08pp	[-1.03, +7.19]pp	0.188	单任务证据不足
Cream cheese	+10.98pp	[+5.20, +16.76]pp	5.46×10^{-4}	明确提升
Orange juice	+5.00pp	[+0.36, +9.64]pp	0.054	边界性证据

8. 按扰动类别分析

LIBERO-Plus 类别	Cases	DINO	VAE	VAE+DINO	Dual-VAE
Camera Viewpoints	93	65.59%	67.74%	97.85%	+30.11pp
Robot Initial States	124	33.87%	75.00%	66.13%	-8.87pp
Language Instructions	103	81.55%	98.06%	100.00%	+1.94pp
Light Conditions	87	58.62%	98.85%	100.00%	+1.15pp
Background Textures	92	57.61%	77.17%	91.30%	+14.13pp
Sensor Noise	126	72.22%	88.89%	100.00%	+11.11pp
Objects Layout	120	55.00%	71.67%	67.50%	-4.17pp

8.1 Dual 的主要收益

Dual 对 Camera、Background 和 Noise 的提升最大。这些类别主要改变视觉外观、观察视角或像素质量，说明 DINO future feature 与 VAE/RGB latent 结合后，能够减少策略对训练图像表面的依赖。

8.2 尚未解决的问题

Dual 在 Robot Initial States 和 Objects Layout 上低于 VAE。这两类变化更直接地改变末端执行器初始位姿、物体几何关系和动作轨迹，表明加入 DINO 特征并不会自动解决控制状态分布变化。后续应优先检查动作条件、状态编码、数据覆盖和空间增强，而不是仅增加视觉表征损失。

Language 与 Light 类别接近饱和，已不适合用于区分 VAE 和 Dual。

9. 与论文结果对比

Variant	论文 LIBERO-Plus	当前三任务	当前-论文
DINO	39.7%	60.13%	+20.43pp
VAE	51.5%	82.15%	+30.65pp
VAE+DINO	66.4%	87.79%	+21.39pp

模型排序与论文一致：**VAE+DINO > VAE > DINO**。当前 Dual-DINO 为 +27.65pp，与论文的 +26.7pp 接近；但当前 Dual-VAE 只有 +5.64pp，低于论文的 +14.9pp。

当前绝对成功率明显更高，主要原因是：

1. 仅针对三个 LIBERO-Object 任务训练，而不是学习更宽的任务分布；
2. 评测只覆盖这三个训练任务的 Plus 变体；
3. 当前 DINO-only 使用统一预算配置，并非发布 artifact 中更长训练、不同学习率和损失权重的严格配置；
4. 当前只有一个训练 seed。

因此，本实验验证的是模型排序和局部趋势，不能将当前绝对数值作为论文指标复现值。

10. 与先前单任务实验的关系

先前 BBQ sauce 单任务、500-step 结果为 DINO 30.71%、VAE 77.14%、Dual 77.86%，Dual-VAE 只有 +0.72pp。本次三任务、1,500-step 实验中：

- BBQ sauce：Dual-VAE 扩大到 +3.08pp；
- 三任务总体：Dual-VAE 为 +5.64pp；
- Dual 在三个任务上的 Plus 成功率更加一致。

这说明增加训练任务多样性和训练预算后，Dual 的优势更容易显现。但任务数和训练步数同时发生变化，无法仅凭两次实验判断提升究竟来自更多任务还是更长训练；若需要因果区分，应补充三任务 500-step 或单任务 1,500-step 对照。

11. 训练指标解释

Step 1,500 的最后一次验证记录为：

Variant	Validation loss	其他记录
DINO	0.1647	action L2 0.0184, action L1 0.0652
VAE	0.1315	inference PSNR 25.2408, SSIM 0.8223
VAE+DINO	0.4361	action L2 0.0452, action L1 0.0801

不同模型的 total loss 由不同目标组成，数值尺度不可横向比较。Dual 的验证 loss 和 action L1/L2 高于 DINO，但闭环成功率明显更高，进一步说明 fixed-noise validation loss 不能作为唯一 checkpoint 选择依据。

12. 关于过拟合的判断

VAE 达到 100% Clean，但在 Plus 上仍有 82.15%，不能据此认定存在严重过拟合。更准确的判断是：

- VAE 存在一定训练分布专门化，尤其在 Camera 和 Background 上弱于 Dual；
- Dual 的 robustness drop 更小，且任务间表现更稳定，说明联合表征具有更好的视觉分布外泛化；
- DINO 的 BBQ sauce Clean 仅 76%，属于明显的基础任务未充分拟合，而不是典型的“Clean 很高、Plus 很低”过拟合模式。

13. 局限性

1. 只有三个基础任务，且都属于“拾取物体并放入篮子”的相同技能族；
2. 只有 seed 42，没有训练 seed 方差；
3. 每个 Plus case 只有一次 rollout，无法估计环境随机性下的重复试验方差；
4. case-level 显著性不能替代跨任务、跨 seed 的显著性；
5. DINO-only 超参数与论文发布 artifact 不完全一致；
6. 当前结果不覆盖 LIBERO-Spatial、Goal、Long 等套件。

14. 结论与建议

本次低成本消融达到预定目标：在相同数据和预算下，VAE+DINO 的 LIBERO-Plus 成功率显著高于 VAE-only 和 DINO-only，且优势主要来自视觉分布变化下的鲁棒性。

建议按以下优先级继续：

1. 使用另一个固定三任务集合和 seed 43 重复实验，检验 Dual+VAE 是否可重复；
2. 针对 Robot Initial States 与 Objects Layout 增加状态/几何相关数据增强或训练覆盖；
3. 若目标是严格复现论文 DINO baseline，按官方 DINO artifact 的学习率、损失权重和训练长度单独重训；
4. 资源允许时扩展至完整 LIBERO-Object 10 任务，再决定是否扩展到四个 suite。

15. 结果与配置位置

训练配置 : configs/data/libero_object_tasks_1_4_7_v3.yaml
训练脚本 : scripts/train_three_task_ablation.sh
评测脚本 : scripts/eval_three_task_ablation.sh
训练输出 : runs/three_task/
评测输出 : evaluate_results/three_task/step1500_seed42/
总体汇总 : evaluate_results/three_task/step1500_seed42/comparison.md
本报告 : docs/THREE_TASK_LIBERO_PLUS_RESULTS_REPORT.md